

國立虎尾科技大學資訊工程科
專題製作報告

指導教授：江季翰老師

結合分群聚合與強化學習
偵測惡意客戶端的聯邦學
習架構

參與成員： 吳承璿 林聖紘 陳志杰

中華民國 115 年 06 月 09 日

摘要

本專題針對聯邦學習在實際應用中可能遇到的兩項問題進行研究：第一，各客戶端所擁有的資料分布不一致，容易影響全域模型的訓練效果；第二，部分客戶端可能遭受攻擊，回傳錯誤或惡意的模型更新，進而降低整體模型的準確率。

為了解決上述問題，我們提出一套結合分群聚合與強化學習的聯邦學習架構。系統會先分析各客戶端回傳的模型更新特徵，例如更新幅度、方向相似度與效能變化，再利用 K-means 將特徵相近的客戶端進行分群，以降低資料分布不一致所造成的影響。同時，系統透過 Deep Q-Network (DQN) 根據各群的異常程度選擇適合的聚合策略，例如正常聚合、降低可疑群的權重，或排除高度異常的群組。

我們以 MNIST 資料集建立模擬環境，並透過不均勻資料切分模擬 Non-IID 情況，同時加入標籤翻轉攻擊以模擬惡意客戶端。期望透過此架構，在保留聯邦學習資料隱私優點的同時，提高模型面對資料差異與惡意攻擊時的穩定性與可靠性。

關鍵字：聯邦學習、強化學習、分群聚合

目錄

一、	緒論	1
1.1	背景.....	1
1.2	動機與目的.....	1
1.3	需求分析.....	2
1.4	系統特色.....	2
1.5	可解決那些問題.....	2
二、	文獻探討	3
2.1	聯邦學習 (Federated Learning)	3
2.2	強化學習 (Reinforcement Learning)	3
2.3	Q-learning	4
2.4	Deep Q-network	5
2.5	K-means	6
三、	研究方法	7
3.1	系統架構圖.....	7
3.2	系統流程圖.....	8
3.3	系統進行步驟.....	9
3.4	客戶端更新特徵設計與作用.....	14
3.5	系統環境.....	16
四、	實驗與結果	16
4.1	實驗資料集與攻擊設定.....	16
4.2	實驗環境.....	18
4.3	實驗結果.....	19

五、	結論	21
六、	參考文獻	22

圖目錄

圖 1 系統架構圖.....	8
圖 2 系統流程圖.....	8
圖 3 FedAvg 於 Non-IID 資料分布下不同惡意客戶端比例 之實驗結果.....	19
圖 4 本專題於 Non-IID 資料分布下不同惡意客戶端比例 之實驗結果.....	20

一、緒論

1.1 背景

過往為保護聯邦學習架構的防禦方法，都是使用固定規則或是固定統計方法偵測惡意更新，例如只根據「極端值」偵測惡意節點。然而攻擊者只需要模仿正常行為，或是讓惡意節點引導更新方向，就能夠輕鬆通過檢查，從而導致聯邦學習架構的效能低下。因此我們認為能夠動態辨別惡意的強化學習是相對萬用的防禦方法，並且在回傳本地模型之前加以分類，不僅能夠解決 Non-IID 的情況，同時也能確保更新全域模型的準確率。

1.2 動機與目的

在閱讀相關文獻時，我們發現儘管已經有人證實了在回傳至伺服器端前將資料加以分類能夠提高模型更新的效率，卻沒有人以此為基礎加強防禦方法。同時，我們也發覺了強化學習強大的適應性非常適合應用在聯邦學習上。因此我們嘗試將兩者混合，以創造更佳的聯邦學習架構為目標。

1.3 需求分析

為了設計一套能抵禦惡意更新、因應 Non-IID 資料特性並可自動調整策略的 FL 架構，我們針對系統需求將整體拆成三個主要模組：特徵提取模組、分群式聚合模組以及 RL 決策模組。其中特徵提取模組需求：FL 伺服器在收到各客戶端的模型更新後，需要能夠量化這些更新的特徵，以便判斷是否存在異常或惡意行為；而分群式聚合模組需求則是：以 K-means 依特徵相似度將客戶端更新分群，並且各群之間要保持獨立；最後的 RL 決策模組：接收回傳資料，並將各群特徵當作 state，接著透過 DQN 學習是否丟棄某些更新，最後根據 reward 決定是否調整全域模型，再發配模型至各客戶端。非功能性需求則是有資料隱私保護、系統需在合理的成本花費下完成、可擴展性、穩定性以及動態適應能力。

1.4 系統特色

本專題為提高聯邦學習架構的安全性以及穩定性，嘗試以強化學習的動態學習結合分群客戶端資料，在能夠防禦惡意攻擊的同時也能夠提升更新模型的效率。

1.5 可解決那些問題

隨著時代的演進，惡意攻擊只會愈加地繁多及複雜，與其被動式的遭受攻擊後再來思考對策，不如在遭受攻擊的同時學習對手的模式，加以學習並馬上應用。同時，將聚合前的資料妥善分類，使得回傳至伺服器端時更能有效地分辨惡意節點。既解決了傳統防禦方法的隱憂，又能將更新效率提升至更上一層。

二、文獻探討

2.1 聯邦學習 (Federated Learning)

聯邦學習 (Federated Learning, FL) 是一種分散式的機器學習架構，主要目的在於讓多個裝置或節點在不分享原始資料的前提下，協同訓練同一個全域模型。在聯邦學習的典型流程中，伺服器首先初始化一個模型並分發給所有參與的客戶端。每個客戶端使用自身的本地資料進行訓練，產生模型更新 (如梯度或權重變化)，並將這些更新回傳給伺服器。伺服器再根據收到的更新進行聚合，例如使用最常見的 Federated Averaging (FedAvg)，將各客戶端的更新做加權平均，形成新的全域模型。接著，伺服器會將更新後的模型再次下發給客戶端，循環進行多輪，直到模型收斂。

2.2 強化學習 (Reinforcement Learning)

強化學習 (Reinforcement Learning, RL) 是一種讓 agent 透過「與環境互動」來學習最佳行為策略的機器學習方法。RL 不依賴固定正確答案，而是依靠「獎勵 (Reward)」去引導模型逐步改進決策。在強化學習中，agent 在每一個時間步會根據目前的狀態 (State) 選擇一個動作 (Action)，環境則會回傳下一個狀態及相對應的獎勵。透過不斷地試錯與累積經驗，agent 會學習到一套能使長期總獎勵最大化的策略 (Policy)。這樣的特性讓 RL 特別適合處理具有動態變化、缺乏明確標準答案或需連續決策的問題。

2.3 Q-learning

Q-learning 是 RL 中最經典的價值型 (Value-based) 演算法之一。其核心目標是學習一個 Q 函數，用來估計在某個狀態 (State) 下執行某個動作 (Action) 所能獲得的長期回報 (Long-term reward)。透過不斷地與環境互動，Q-learning 能逐步更新這個估計值，並最終找到使累積獎勵最大化的最佳策略。演算法會維護一張「Q-table」，其索引為(State, Action) 組合，內容則是對應的 Q 值。

每次 agent 執行動作後，會根據回饋的即時獎勵與下一狀態的最大 Q 值，使用以下更新規則調整原本的估計：

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

- s : 目前狀態
- a : 在狀態 s 下採取的動作
- r : 執行動作後獲得的獎勵
- α : 學習率
- γ : 折扣因子，用來衡量未來獎勵的重要性

2.4 Deep Q-network

Q-learning 雖然概念簡單，但在面對高維度或連續狀態空間時，會因 Q-table 過於龐大而無法實際運作。為了解決此問題，DeepMind 在2015年提出 Deep Q-Network(DQN)，將深度神經網路 (DNN) 用作 Q 函數的近似器，使 Q-learning 能處理複雜環境中的決策問題。

在 DQN 中，神經網路會輸入目前的狀態 (state)，並輸出對所有可選動作的 Q 值估計。訓練目標是讓網路的輸出逼近 Q-learning 的更新目標值：

$$y = r + \gamma \max_{a'} Q(s', a')$$

為了提升收斂穩定性與避免訓練震盪，DQN 引入了兩個重要機制：

1. 經驗回放 (Experience Replay) : DQN 不會立即使用最新的資料訓練，而是將 agent 的歷史經驗 (s, a, r, s') 儲存在 replay buffer 中，並從中隨機抽取 mini-batch 進

行訓練。

2. 目標網路 (Target Network) : target network (負責提供穩定的目標值) 的參數會每隔固定步數才從 online network (負責選擇動作與更新) 複製一次，而不是每次更新都同步，避免 Q-learning 更新目標過於動態而導致不收斂。

2.5 K-means

K-means 是一種常用且高效的分群 (Clustering) 演算法，其目標是將資料依相似度分為 K 個群組，使同一群中的資料彼此相近，而不同群之間差異較大。由於其計算效率高、概念簡單且擅長處理大型資料集，因此在許多機器學習與資料分析情境中被廣泛使用，也適合作為聯邦學習環境中的預處理或群組化方法。K-means 的核心概念是利用「群中心 (Centroid)」來代表每一個群組。演算法透過反覆更新資料的分群結果以及群中心位置，使整體群內差異最小。

三、研究方法

3.1 系統架構圖




圖 1 系統架構圖

3.2 系統流程圖




圖 2 系統流程圖

3.3 系統進行步驟

系統流程主要分為資料準備、聯邦學習訓練、惡意攻擊模擬、更新特徵分析、客戶端分群、強化學習決策與全域模型更新等階段。整體執行步驟如下所示。

Step 1：建立實驗資料集與聯邦學習環境

首先使用 MNIST 手寫數字資料集作為模型訓練與測試資料。MNIST 包含數字 0 至 9 共十種類別，且每張影像大小為 28×28 像素，適合作為影像分類與聯邦學習架構驗證之基準資料集。

在聯邦學習環境中，透過 Flower 框架模擬多個客戶端參與模型訓練的情境。實驗設定共建立 10 個客戶端，每個客戶端都具有自己的本地訓練資料，並於本地端完成模型訓練後，將模型更新結果回傳至伺服器端。

Step 2：建立 Non-IID 資料分布情境

為模擬實際的聯邦學習環境中，不同終端裝置所蒐集到的資料類型與數量可能存在差異之情況，我們將 MNIST 資料以非均勻方式分配至各客戶端，使不同客戶端擁有不同比例的數字類別資料。

例如，部分客戶端可能持有較多數字 0 或數字 5 的影像，而其他客戶端則可能持有較多其他類別資料。此種資料分布方式稱為 Non-Independent and Identically Distributed (Non-IID)。在此情境下，各客戶端的本地訓練方向可能產生差異，進而影響全域模型的聚合穩定性。因此，本專題透過此設定驗證分群聚合方法對 Non-IID 問題之處理效果。

Step 3：初始化全域模型並發送至客戶端

實驗開始時，伺服器端會先建立一個初始全域模型。此模型採用卷積神經網路 (Convolutional Neural Network, CNN) 進行 MNIST 手寫數字分類任務。

完成模型初始化後，伺服器會將目前的全域模型參數傳送至各個參與訓練的客戶端。所有客戶端在每一輪訓練開始時，皆以相同的全域模型作為本地訓練的起點，以確保後續回傳之模型更新能夠進行比較與聚合。

Step 4：客戶端進行本地模型訓練

各客戶端接收到全域模型後，會使用自身持有的本地資料進行模型訓練。本地訓練過程僅於客戶端端點執行，原始資料不會直接傳送至伺服器，因此可保留聯邦學習所強調的資料隱私特性。

每個客戶端完成本地訓練後，會產生一組新的本地模型參數。正常客戶端所回傳之模型更新，主要反映其本地資料對模型學習方向的影響；而惡意客戶端則可能因資料遭到竄改，使回傳之更新對全域模型造成不良影響。

Step 5：模擬惡意客戶端之標籤翻轉攻擊

為驗證本專題架構對惡意更新的偵測能力，實驗中設定部分客戶端為惡意客戶端，並使其執行 標籤翻轉攻擊 (Label-Flipping Attack)。

在此攻擊方式中，惡意客戶端會將原本正確的資料標籤修改為錯誤類別，再使用被竄改後的資料進行本地模型訓練。例如，原本屬於數字 1 的影像可能被修改為其他數字類別。由於模型在錯誤標籤下進行學習，惡意客戶端所產生的模型更新可能會降低後續全域模型的分類準確率。

完成本地訓練後，正常客戶端與惡意客戶端皆會將各自的模型更新回傳至伺服器端，使系統能在不知道客戶端身分的情況下，根據更新特徵判斷其異常程度。

Step 6：計算客戶端模型更新特徵

伺服器端接收到各客戶端回傳之模型更新後，會比較客戶端本地模型與該輪訓練開始前的全域模型，並計算三項主要更新特徵，分別為「更新幅度 (L2 Norm)、更新方向相似度 (Cosine Similarity) 及效能變化 (Loss 變化)」。

透過上述三項特徵，系統能從更新大小、更新方向與模型效能三個角度觀察各客戶端回傳結果之差異，並作為後續異常判斷與分群聚合之基礎。

$$norm_i^{(t)} = ||\Delta w_i^{(t)}||_2 = \left[\sum_{j=1}^n |\Delta w_{ij}^{(t)}|^2 \right]^{1/2}$$

$$cos_i^{(t)} = \frac{\Delta w_i^{(t)} \cdot \Delta w_{avg}^{(t)}}{\|\Delta w_i^{(t)}\|_2 \|\Delta w_{avg}^{(t)}\|_2}$$

$$\Delta L_i^{(t)} = L(w^t + \Delta w_i^t; D_{proxy}) - L(w^t; D_{proxy})$$

- w : 模型參數
- t : 目前第 t 回合
- i : 第 i 個客戶端

Step 7 : 計算異常程度並進行客戶端分群

由於不同特徵的數值範圍可能存在差異，我們進一步利用 Robust Z-score 將各項特徵轉換為可比較之異常程度。Robust Z-score 以中位數及中位數絕對偏差作為衡量基礎，相較於一般平均值與標準差，更不容易受到極端異常值影響，因此適合用於分析可能包含惡意更新的客戶端資料。

$$anomalScore_i^{(t)} = 0.4 * Z(norm_i^{(t)}) + 0.4 * Z(1 - cos_i^{(t)}) + 0.2 * Z(\Delta L_i^{(t)})$$

- $Z()$: Robust Z-score, 用來轉換成異常程度

完成異常程度計算後，接著使用 K-means 分群演算法，依據各客戶端的異常程度之相似性進行分群。我們將客戶端分為三個群組，以對應不同程度的更新狀態：

1. 正常更新群組：更新特徵接近一般客戶端，可正常參與模型聚合。
2. 輕微異常群組：更新特徵存在一定程度偏離，但尚未達到完全排除標準。
3. 高度異常群組：更新特徵明顯偏離正常範圍，可能受到惡意攻擊影響。

透過分群處理，可避免直接將所有客戶端更新一併平均，使具有相似更新特性的客戶端先被歸類，再交由後續決策模組選擇適當的聚合方式。

Step 8：透過 DQN 選擇聚合策略

完成客戶端分群後，系統將各群組之異常資訊作為強化學習模組的狀態輸入，並透過 Deep Q-Network (DQN) 選擇適當的聚合策略。

聚合決策可分為三種動作：

1. 正常聚合：當群組更新狀態較為正常時，保留其原有影響程度參與全域模型聚合。
2. 降低可疑群組權重：當群組具有輕微異常情形時，仍保留其部分資訊，但降低該群組對全域模型的影響程度。
3. 排除或大幅降低高度異常群組影響：當群組更新呈現高度異常時，系統將限制其參與聚合，以避免惡意更新污染全域模型。

透過 DQN 的決策機制，系統不再僅依靠固定規則處理所有客戶端更新，而是能根據目前觀察到的異常狀態，選擇較適合之聚合方式。

Step 9：完成模型聚合並更新全域模型

伺服器端根據 DQN 所選擇之聚合策略，對不同群組的客戶端模型更新進行加權處理，再將處理後的結果聚合成新的全域模型。

在此階段，正常群組可保有較高的聚合影響力；具有可疑情形的群組則會被降低權重；高度異常群組則可能被排除或僅保留極低權重。透過此方式，可降低惡意客戶端對全域模型造成的負面影響，同時保留正常客戶端所提供之有效學習資訊。

完成本輪聚合後，伺服器會將更新後的全域模型再次發送至各客戶端，進入下一輪聯邦學習訓練。

3.4 客戶端更新特徵設計與作用

在聯邦學習中，伺服器無法直接取得各客戶端的原始訓練資料，因此難以直接判斷客戶端是否存在惡意行為。所以我們透過分析各客戶端回傳之模型更新特徵，作為分群與異常判斷的依據。系統主要採用更新幅度、更新方向相似度與效能變化三項特徵，以描述不同客戶端更新結果之差異。

1. 更新幅度 (L2 Norm)

更新幅度用於衡量客戶端本地訓練後，模型參數相對於原始全域模型發生的變化程度。若某一客戶端回傳之模型更新幅度明顯大於其他客戶端，可能表示其本地資料分布與整體差異較大，也可能代表該客戶端受到攻擊並產生異常更新。

因此，我們將更新幅度作為判斷模型更新是否過度偏離正常範圍的重要依據。透過此特徵，系統能初步辨識可能對全域模型造成較大影響的客戶端更新。

2. 更新方向相似度 (Cosine Similarity)

更新方向相似度用於衡量不同模型更新方向之間的一致程度。一般而言，正常客戶端即使具有不同的本地資料，其模型更新方向仍可能保有一定程度的相似性；相反地，若客戶端受到惡意操作，其更新方向可能明顯偏離其他客戶端。

我們利用餘弦相似度觀察客戶端更新方向的差異。當某一客戶端的更新方向與整體趨勢差異較大時，系統可將其視為較具可疑性的更新，並在後續分群與聚合決策中降低其影響程度。

3. 效能變化 (Loss 變化)

效能變化用於觀察客戶端完成本地訓練前後，模型損失值是否出現異常改變。若模型經過本地訓練後損失值下降，通常表示該更新有助於模型學習；反之，若損失值異常升高，則可能表示該客戶端回傳之更新對模型訓練造成不利影響。

因此，我們將 Loss 變化納入特徵分析，使系統除了觀察參數更新的大小與方向外，也能進一步考量模型效能是否受到影響。

3.5 系統環境

首先開發環境以 Windows 11 PC 個人電腦為硬體設備，Visual Studio Code 做為程式撰寫的工具，搭配 Git 協助版本控制。作業系統是以 Ubuntu 22.04為主。開發語言則是以 Python 3.10為主，配合 TensorFlow (建立與訓練深度學習模型)、Flower (建構 FL 架構與模擬多個客戶端)、NumPy、pandas (資料處理與數值運算) 等套件的使用。

四、實驗與結果

4.1 實驗資料集與攻擊設定

1. MNIST 資料集

本專題採用 MNIST 手寫數字資料集作為聯邦學習模型的訓練與測試資料。MNIST 是影像分類研究中常用的基準資料集，由美國國家標準與技術研究院 (NIST) 的手寫數字影像整理而成，並經過影像大小統一與置中處理。

此資料集包含數字 0 至9 共十種類別，總共有 70,000 張灰階影像，其中 60,000 張作為訓練資料，10,000 張作為測試資料。每張影像大小為 28×28 像素。

本專題選擇 MNIST 的原因，是因為其分類任務明確、資料規模適中，適合用來建立聯邦學習模擬環境。此外，由於資料本身較單純，實驗結果較能專注呈現 Non-IID 資料分布與惡意客戶端攻擊對聯邦學習模型的影響，而不會受到過於複雜的影像特徵干擾。

2. Non-IID 資料分布設定

為了模擬實際聯邦學習環境中不同客戶端資料內容不一致的情況，本專題將 MNIST 資料以非均勻方式分配給各個客戶端。亦即，不同客戶端可能擁有較多特定數字類別的資料，而非平均取得所有類別。

此種設定可模擬實際 IoT 裝置因使用環境、蒐集位置或操作行為不同，導致本地資料分布有所差異的情境，並用以驗證本專題提出的分群聚合方法是否能降低 Non-IID 對模型訓練造成的影響。

3. 標籤翻轉攻擊設定

本專題以標籤翻轉攻擊 (Label-Flipping Attack) 模擬惡意客戶端行為。被設定為惡意的客戶端會將原本正確的資料標籤修改為錯誤類別，再使用這些被竄改的資料進行本地訓練，最後將產生的模型更新回傳至伺服器。

透過此方式，可觀察惡意更新是否會使全域模型準確率下降，並驗證本專題所設計的異常判斷與聚合策略是否能降低攻擊所造成的影響。

4.2 實驗環境

為驗證本專題所提出之聯邦學習架構於 Non-IID 資料分布與惡意客戶端攻擊情境下之運作效果，我們於個人電腦上建置模擬實驗環境，並透過多個虛擬客戶端模擬終端裝置參與聯邦學習訓練之情境。

我們以 Ubuntu 22.04 作為主要執行環境，使用 Visual Studio Code 進程式開發，並搭配 Git 進行版本管理。程式開發語言採用 Python，其中以 TensorFlow / Keras 建立影像分類模型與自行實作之 Deep Q-Network (DQN) 決策模型；聯邦學習訓練流程與多客戶端模擬則透過 Flower 框架完成。此外，系統使用 NumPy 進行模型更新特徵與異常分數計算，並透過 scikit-learn 中的 K-means 演算法進行客戶端分群。

在實驗設定方面，則採用 MNIST 手寫數字資料集作為模型訓練與測試資料，並模擬 10 個客戶端參與聯邦學習訓練。為呈現實際環境中不同客戶端所擁有資料類別與數量可能存在差異之情況，實驗採用非均勻方式分配資料，以建立 Non-IID 資料分布情境。同時，系統設定部分客戶端執行標籤翻轉攻擊 (Label-Flipping Attack)，藉此模擬惡意客戶端回傳受污染模型更新之狀況。

4.3 實驗結果




圖 3 FedAvg 於 Non-IID 資料分布下不同惡意客戶端比例之實驗結果

由圖 3 可觀察到，在 Non-IID 資料分布情境下，傳統 FedAvg 對惡意客戶端比例增加具有明顯的敏感性。當惡意客戶端比例介於 0% 至 30% 時，整體模型準確率 (All-Acc) 仍維持在較高水準，攻擊成功率 (ASR) 亦接近於零，顯示少量惡意更新尚未明顯影響整體分類結果。

然而，當惡意客戶端比例提升至 40% 與 50% 時，攻擊成功率迅速上升至接近 100%，同時來源類別準確率 (Src-Acc) 明顯下降至接近 0%。此結果表示，模型雖然在整體資料上的準確率仍維持一定程度，但針對遭受標籤翻轉攻擊之特定類別，已幾乎無法進行正確辨識。




圖 4 本專題於 Non-IID 資料分布下不同惡意客戶端比例之實驗結果

由圖 4 可觀察到，在 Non-IID 資料分布與標籤翻轉攻擊情境下，本文所提出之 K-means 分群與強化學習聚合方法，於不同惡意客戶端比例下皆能維持穩定的模型表現。即使惡意客戶端比例提高至 40% 與 50%，整體準確率 (All-Acc) 仍維持於約 94% 以上，來源類別準確率 (Src-Acc) 亦保持在較高水準。

此外，圖中攻擊成功率 (ASR) 在各組實驗中皆維持於較低範圍，顯示本文方法能有效降低標籤翻轉攻擊對全域模型造成的影響。

五、結論

本專題針對聯邦學習在 IoT 環境中易受 Non-IID 分布與惡意攻擊所影響的問題，提出一套結合分群式聚合與強化學習的聯邦學習架構。透過 K-means 分群，我們能有效降低客戶端資料差異造成的聚合不穩定；並藉由 DQN 模型學習識別可疑的更新向量，使系統能主動過濾潛在的惡意行為，增強整體模型的安全性。

然而，依然有許多可以改進的地方：像是計算成本會隨著客戶端數量增加，可能帶來額外伺服器負擔；目前主要針對 poisoning 攻擊，尚未全面涵蓋所有可能的進階攻擊方式，只要攻擊者刻意針對三點特徵進行修改，很容易就能繞過 RL agent 的判斷。未來我們會朝著這些點加以優化相關設計。

六、參考文獻

- [1] M. Ghasemi, A. H. Moosavi, I. Sorkhoh, A. Agrawal, F. Alzhouri, and D. Ebrahimi, "An Introduction to Reinforcement Learning: Fundamental Concepts and Practical Applications," Aug. 2024. [Online]. Available: <https://arxiv.org/abs/2408.07712>. [Accessed September 18, 2025].
- [2] A. M. Fahim, A. M. Salem, F. A. Torkey, and M. A. Ramadan, "An Efficient Enhanced K-means Clustering Algorithm," *Journal of Zhejiang University-SCIENCE A*, Vol. 7, No. 10, pp. 1626–1633 (2006).
- [3] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, and B. Agüera y Arcas, "Communication-Efficient Learning of Deep Networks from Decentralized Data," *Proc. of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, Fort Lauderdale, Florida, USA, pp. 1273–1282 (2017).
- [4] A. Alruwaili, S. M. N. Islam, and I. Gondal, "Fed-DTB: A Dynamic Trust-Based Framework for Secure and Efficient Federated Learning in IoV Networks: Securing V2V/V2I Communication," *Journal of Cybersecurity and Privacy*, Vol. 5, No. 3, Article 48 (2025).
- [5] L. U. Khan, W. Saad, Z. Han, E. Hossain, and C. S. Hong, "Federated Learning for Internet of Things: Recent Advances, Taxonomy, and Open Challenges," *IEEE Communications Surveys & Tutorials*, Vol. 23, No. 3, pp. 1759–1799 (2021).
- [6] S. Vahidian, M. Morafah, W. Wang, V. Kungurtsev, C. Chen, M. Shah, and B. Lin, "Efficient Distribution Similarity Identification in Clustered Federated Learning via Principal Angles between Client Data Subspaces," *Proc. of the Thirty-Seventh AAAI Conference on Artificial Intelligence (AAAI-23)*, Washington, DC, USA, Vol. 37, No. 8, pp. 10043–10052 (2023).
- [7] A. Uprety, D. B. Rawat, and B. Sadler, "Human Immune System Inspired Security for Federated Learning-Empowered Internet of Things," *ACM Transactions on Internet of Things*, Vol. 6, No. 2, Article 11, pp. 1–18 (2025).
- [8] C. Fung, C. J. M. Yoon, and I. Beschastnikh, "Mitigating Sybils in Federated Learning Poisoning," Aug. 2018. [Online]. Available: <https://arxiv.org/abs/1808.04866>. [Accessed October 14, 2025].
- [9] iThome, 「[魔法陣系列] Deep Q Network (DQN) 之術式解析」, 擷取於: 2025/10/27。
<https://ithelp.ithome.com.tw/articles/10208668>
- [10] iThome, 「[魔法陣系列] Convolutional Neural Network (CNN) 之術式解析」, 擷取於: 2025/11/08。
<https://ithelp.ithome.com.tw/articles/10204737>

[11] R. Liao, 「Reinforcement Learning 進階篇：Deep Q-Learning」, Medium, 擷取於：2025/11/21。

<https://medium.com/pyladies-taiwan/reinforcement-learning-%E9%80%B2%E9%9A%8E%E7%AF%87-deep-q-learning-26b10935a745>

[12] 王柏鈞, 「聯邦學習 (Federated Learning)：模型之間的知識分享體系」, Medium, 擷取於：2025/12/05。

<https://medium.com/%E6%A9%9F%E5%99%A8%E5%AD%B8%E7%BF%92%E7%9F%A5%E8%AD%98%E6%AD%B7%E7%A8%8B/%E8%81%AF%E9%82%A6%E5%AD%B8%E7%BF%92%E7%9A%84%E7%B0%A1%E5%96%AE%E4%BB%8B%E7%B4%B9-776924277d13>

[13] 王柏鈞, 「聯邦學習的問題設定」, Medium, 擷取於：2025/12/17。

<https://medium.com/%E6%A9%9F%E5%99%A8%E5%AD%B8%E7%BF%92%E7%9F%A5%E8%AD%98%E6%AD%B7%E7%A8%8B/%E8%81%AF%E9%82%A6%E5%AD%B8%E7%BF%92%E7%9A%84%E5%95%8F%E9%A1%8C%E8%A8%AD%E5%AE%9A-7e10e1f2053a>

[14] Flower Labs, "Quickstart TensorFlow - Flower Framework," n.d. [Online]. Available: <https://flower.ai/docs/framework/tutorial-quickstart-tensorflow.html>. [Accessed February 23, 2026].

[15] iThome, 「沒有實作所以只好講幹話系列 (一)：從 Loss 到梯度下降」, 擷取於：2026/03/11。

<https://ithelp.ithome.com.tw/articles/10216635>

[16] F. Sattler, K.-R. Müller, and W. Samek, "Clustered Federated Learning: Model-Agnostic Distributed Multi-Task Optimization under Privacy Constraints," IEEE Transactions on Neural Networks and Learning Systems, Vol. 32, No. 8, pp. 3710–3722 (2021).

[17] Y. LeCun, C. Cortes, and C. J. C. Burges, "The MNIST Database of Handwritten Digits," n.d. [Online]. Available: <https://yann.lecun.com/exdb/mnist/>. [Accessed May 19, 2026].

[18] V. Mnih, K. Kavukcuoglu, D. Silver, et al., "Human-Level Control Through Deep Reinforcement Learning," Nature, Vol. 518, No. 7540, pp. 529–533 (2015).

[19] N. M. Jebreel, J. Domingo-Ferrer, D. Sánchez, and A. Blanco-Justicia, "LFighter: Defending against the Label-flipping Attack in Federated Learning," Neural Networks, Vol. 170, pp. 111–126 (2024).