

結合分群聚合與強化學習偵測惡意客戶端的 聯邦學習架構

A Federated Learning Framework with Cluster- Based Aggregation for Malicious Client Detection Using Reinforcement Learning

吳承璿 林聖紘 陳志杰


2026/06/09

大綱

- 實驗背景
- 實驗動機
- 實驗步驟
- 實驗目標
- 資料集類別
- 攻擊方式
- 實驗設計
- 實驗結果


實驗背景

- 聯邦學習讓資料保留在本地端
- 客戶端 (Client) 只回傳模型更新，不直接上傳原始資料
- 伺服器端 (Server) 聚合多個 Client 的模型，形成全新的全域模型 (Global Model)




實驗動機

1. Non-IID 的資料分布：不同 Client 的資料類別比例不同，導致模型更新方向差異大



模型訓練結果受到影響

2. 惡意客戶端攻擊：部分 Client 端可能回傳被汙染或異常的模型，影響 Global Model



模型辨識準確率降低

實驗步驟

1. 建立一個聯邦學習環境，模擬多個 Client 共同訓練模型
2. 使用 Non-IID 資料分布，模擬不同 Client 資料類別比例不一致的情況
3. 加入標籤翻轉攻擊，觀察惡意 Client 對 Global Model 的影響
4. 透過 K-means 分群，將模型更新特徵相近的 Client 分在同一群
5. 結合強化學習機制，根據異常分數調整聚合權重
6. 觀察此架構是否能降低惡意 Client 對模型準確率的影響

實驗目標

在 Non-IID 資料分布下加入不同比例的標籤翻轉攻擊，觀察傳統 FedAvg 是否會受到惡意更新影響，並比較我們提出的架構：

- 模型能夠正確辨識訓練資料（圖片）
- 強化學習決策模組能夠正確分辨惡意客戶端
- 訓練結果不受到訓練資料分布的影響

資料集類別

MNIST 手寫數字資料集

- 影像內容：0~9 的手寫數字圖片
- 類別數量：共 10 類
- 圖片大小：28 × 28 灰階影像
- 訓練目標：讓 Client 端判斷圖片是哪一個數字




攻擊方式

標籤翻轉攻擊 (Label-flipping attack)

惡意 Client 只會改變訓練資料的標籤，不會改變資料本身

↳ 導致訓練完的模型學習到錯誤的分類規則

例如：將數字為 1 的圖片改為類別 7




~~Label 1~~ → Label 7

實驗設計


類別	設定內容
開發語言	Python
聯邦學習框架	Flower
深度學習框架	TensorFlow / Keras
資料集	MNIST 手寫數字資料集
模型架構	CNN 卷積神經網路
Client 數量	10 個 Clients
資料分布	Non-IID 資料分布
攻擊方式	Label Flipping Attack
惡意 Client 比例	10%~50% , 10 個 Clients 中有 1~5 個惡意 Clients
訓練回合數	50 輪

實驗結果



- All-Acc：整體準確率。
- Src-Acc：來源準確率（Source Accuracy）。指被修改標籤的圖片依然能被正確辨識的準確率。
- ASR：攻擊成功率（Attack Success Rate）。
- TE X 10：測試誤差放大 10 倍。

實驗結果



- All-Acc：整體準確率。
- Src-Acc：來源準確率（Source Accuracy）。指被修改標籤的圖片依然能被正確辨識的準確率。
- ASR：攻擊成功率（Attack Success Rate）。
- TE X 10：測試誤差放大 10 倍。